Plan de Proyecto de Ciencia de Datos

Análisis de factores asociados a los costos anuales de atención médica en una aseguradora de salud privada

Campo	Detalle
Asignatura	SCY1102 Gestión de Proyectos de Datos
Evaluación	Evaluación Parcial N°4 · Encargo con Presentación
Integrante	Vicente Gabriel Zepeda Rojas (trabajo individual; asume los roles de la Tabla 10)
Docente	Jorge Alberto Moscoso Santander
Fecha de entrega	14/10/2026

1. Documentación de requerimientos

1.1 Descripción del cliente y sus necesidades

El cliente es una aseguradora de salud privada que cuenta con datos históricos de 1.338 afiliados: edad, sexo, índice de masa corporal (IMC), tabaquismo, número de hijos, región de residencia y costo anual de atención médica. Necesita comprender qué características se asocian a un mayor costo para tres fines: estimar presupuestos anuales por grupo, mejorar la planificación del sistema y focalizar programas preventivos. Hoy presupuesta con el promedio de costo (US$ 13.270), un indicador distorsionado por pocos casos de alto costo, y no tiene una lectura de los factores que sustente la prevención. Los actores son la gerencia, que decide sobre la ampliación de programas; el área de finanzas y actuarial, que usa el presupuesto por grupo; y el área de prevención, que diseña y opera los programas.

1.2 Requerimientos funcionales

ID	Requerimiento	Descripción	Prioridad
RF1	Identificar factores asociados al costo	Determinar qué características (edad, IMC, tabaquismo, hijos, sexo y región) se asocian al costo anual.	Must
RF2	Cuantificar el efecto de cada factor	Estimar el cambio porcentual del costo por factor, con los demás constantes.	Must
RF3	Estimar el costo esperado por grupo	Entregar el costo promedio anual por grupo de afiliados para elaborar presupuestos.	Must
RF4	Segmentar afiliados para prevención	Agrupar afiliados por tabaquismo, IMC, edad y región para priorizar la prevención.	Must
RF5	Visualizar resultados	Dashboard interactivo con filtros por tabaquismo y comparaciones por IMC, edad, región e hijos.	Should
RF6	Alertar desviaciones del presupuesto	Señalar cuando el gasto real se aparta del presupuesto por grupo.	Could

1.3 Requerimientos no funcionales

ID	Categoría	Requerimiento	Prioridad
RNF1	Privacidad de datos de salud	Datos anonimizados y tratados conforme a la Ley N° 19.628 sobre protección de la vida privada. Los datos de salud son datos sensibles en esa ley.	Must
RNF2	Reproducibilidad	El análisis se repite con la misma semilla aleatoria (42) y código documentado.	Should
RNF3	Interpretabilidad	Resultados expresados como asociaciones y cambios porcentuales comprensibles para personas no técnicas.	Must

ID	Categoría	Requerimiento	Prioridad
RNF4	Usabilidad	El dashboard se ve correctamente en computador y en celular.	Could

1.4 Priorización (MoSCoW)

Prioridad	Requerimientos	Justificación
Must	RF1, RF2, RF3, RF4, RNF1, RNF3	Sin identificar, cuantificar y presupuestar por grupo, y sin cumplir la normativa, el proyecto no cumple su objetivo.
Should	RF5, RNF2	Sostienen el uso del análisis en presupuestos y permiten verificar las conclusiones.
Could	RF6, RNF4	Aportan valor, pero dependen del tiempo disponible.
Won't	Predicción precisa del costo individual; integración con sistemas de la aseguradora; implementación completa del programa preventivo	La base no alcanza precisión individual (R^2 de validación cruzada de 31,8%, sección 2.4). La implementación excede el plazo de 12 semanas.

1.5 Trazabilidad: objetivo, requerimiento, entregable y KPI

Objetivo del cliente	Requerimientos	Entregable	KPI que lo verifica
Estimar presupuestos	RF1, RF2, RF3	E3 modelo validado	Error medio del modelo; desviación del presupuesto
Mejorar la planificación	RF5, RNF4	E4 dashboard; E5 informe	Hitos cumplidos a tiempo; uso del dashboard
Orientar programas preventivos	RF4, RF6, RNF1	E5 informe y propuesta de piloto	Costo promedio de fumadores; costo por participante

2. Alcance y metodología

2.1 Declaración de alcance

El proyecto analiza los factores asociados al costo anual de 1.338 afiliados mediante estadística descriptiva y regresión lineal sobre el logaritmo del costo, con validación cruzada de cinco particiones. Entrega una base validada, un modelo de factores con estimación del costo por grupo, un dashboard, un informe y una presentación, y propone un piloto preventivo. Quedan fuera del alcance la predicción del costo individual, la implementación de programas, la integración con los sistemas de la aseguradora y el análisis causal.

2.2 Entregables y criterios de aceptación

Entregable	Semana	Criterio de aceptación
E1 Acta de constitución	S2	Firmada por el patrocinador; requerimientos priorizados según MoSCoW.
E2 Base validada y documentada	S4	1.338 registros; cero valores nulos en las variables del modelo; diccionario de variables entregado.
E3 Modelo de factores validado	S7	Dos modelos comparados (AIC y validación cruzada de 5 particiones); efectos con p-valor reportado; supuestos de residuos revisados; estimación de costo por grupo.
E4 Dashboard interactivo	S9	Filtros operativos; carga en menos de 3 segundos; visible en celular.
E5 Informe, presentación y propuesta de piloto	S12	Aprobado por el patrocinador; presentación de 10 minutos con defensa ante preguntas.

2.3 Supuestos y restricciones

- **Supuesto 1.** Los registros son representativos de la cartera. Se valida en S4 con el patrocinador.
- **Supuesto 2.** La base está completa y es consistente. Se verifica con la ausencia de nulos en E2.

- **Supuesto 3.** El caso se trabaja con el conjunto público de seguros (Choi, s.f.), con la misma estructura y tamaño que la base del cliente. Los resultados deben reproducirse con datos reales antes de decidir.
- **Supuesto 4.** El punto de equilibrio del programa supone que el 25% de los participantes deja de fumar y que esos casos reducen su costo en la proporción medida.
- **Restricción 1.** La base no incluye diagnósticos, historial clínico, tipo de plan ni medicamentos.
- **Restricción 2.** El plazo es de 12 semanas. Se usan herramientas gratuitas (Python, Google Colab, Trello y Canva).
- **Restricción 3.** El trabajo se realiza en sesiones de 5 horas en sala de proyectos, con un solo integrante que asume los seis roles.

2.4 Justificación del marco metodológico

Se adopta CRISP-DM (Chapman et al., 2000) por cinco razones. Primero, es independiente de la industria y se aplica al sector salud y seguros. Segundo, sus fases corresponden a entregables verificables, lo que permite controlar el avance y las compuertas de la sección 3.2. Tercero, es iterativo: el análisis exploratorio puede obligar a volver a la preparación o al modelado, como ocurrió al detectar la interacción entre tabaquismo e IMC. Cuarto, tiene una fase de negocio que asegura que el modelo responda al problema del cliente. Quinto, está ampliamente documentado, lo que favorece la reproducibilidad.

Se descartaron dos alternativas. TDSP (Microsoft, s.f.) está pensado para equipos de ingeniería con infraestructura en la nube y producción de modelos, lo que excede el presupuesto y el plazo, porque el proyecto es un análisis con piloto y no un sistema en producción. Un modelo en cascada impediría volver atrás cuando el análisis revele un problema, algo que este proyecto anticipa. Scrum se descarta porque requiere un dueño de producto disponible de forma continua, y el cliente participa en hitos.

Hallazgos preliminares que justifican las decisiones. La exploración del conjunto de referencia muestra que el costo medio (US$ 13.270) está muy por encima de la mediana (US$ 9.382). El 20,4% de los afiliados supera US$ 20.000 al año y el 10% de mayor costo concentra el 31,8% del gasto. Los fumadores son el 20,5% de los afiliados y generan el 49,5% del gasto. Entre fumadores, el costo medio con IMC ≥ 30 es de US$ 41.558, frente a US$ 21.363 con IMC < 30; en no fumadores la diferencia es de 11%. Por eso el modelo incluye la interacción tabaquismo × IMC, y el presupuesto se hace por grupos y no por afiliado.

3. Implementación del marco metodológico

3.1 Fases, actividades, entregables y responsables

Fase CRISP-DM	Actividades	Entregable	Responsable
1. Comprensión del negocio	Entrevista con la aseguradora; definir objetivos, preguntas y criterio de éxito (reducción del costo por participante de al menos 4,9%).	E1	Jefe de proyecto
2. Comprensión de los datos	Análisis exploratorio: distribuciones, nulos, correlaciones y asimetría del costo.	Informe exploratorio	Analista de datos; especialista en seguridad
3. Preparación de los datos	Codificación de variables, categorías de edad e IMC, control de calidad, anonimización.	E2	Ingeniero de datos
4. Modelado	Regresión sobre el logaritmo del costo (M1 sin interacción y M2 con interacción tabaquismo × IMC).	Modelo candidato	Científico de datos
5. Evaluación	Comparar AIC y validación cruzada; revisar supuestos de residuos; interpretar efectos con la aseguradora.	E3	Científico de datos; analista de negocio
6. Despliegue	Dashboard (E4); informe, presentación y propuesta de piloto (E5).	E4 y E5	Analista de datos; analista de negocio

3.2 Compuertas de avance

El proyecto avanza de una fase a la siguiente solo si se cumple el criterio de compuerta. Si no se cumple, el equipo corrige en la misma fase o vuelve a una anterior, según el carácter iterativo de CRISP-DM.

Compuerta	Semana	Condición para avanzar	Aprueba
G1	S2	E1 firmada; objetivos y preguntas validados con la aseguradora.	Patrocinador
G2	S4	E2 cumple el criterio de aceptación; EDA concluido.	Jefe de proyecto
G3	S7	E3 cumple el criterio de aceptación; interpretación validada con el patrocinador.	Patrocinador
G4	S9	E4 cumple el criterio de aceptación en computador y celular.	Jefe de proyecto
G5	S12	E5 aprobado; presentación realizada.	Patrocinador

3.3 Roles involucrados

- **Jefe de proyecto:** planificación, control de riesgos y comunicación con la aseguradora.
- **Ingeniero de datos:** integra la fuente, carga la base, aplica la limpieza y mantiene la versión del conjunto de datos.
- **Especialista en seguridad y cumplimiento:** anonimiza identificadores, controla el acceso a la base y verifica el cumplimiento de la Ley N° 19.628.
- **Analista de datos:** análisis exploratorio y dashboard.
- **Científico de datos:** modelado, validación estadística y reproducibilidad.
- **Analista de negocio:** traducción de resultados en decisiones de presupuesto y prevención, e informe final.
- **Patrocinador (aseguradora):** valida requerimientos, base y resultados.

4. Componentes de planificación

4.1 Estructura de desglose del trabajo (WBS)

Código	Paquete de trabajo	Entregable
1	Gestión del proyecto (transversal)	Actas de seguimiento
1.1	Planificación y control de riesgos	E1
2	Fase 1 CRISP-DM: comprensión del negocio	Requerimientos validados
3	Fase 2 CRISP-DM: comprensión de los datos	Informe exploratorio
4	Fase 3 CRISP-DM: preparación de los datos	E2
5	Fase 4 CRISP-DM: modelado	Modelo candidato
6	Fase 5 CRISP-DM: evaluación	E3
7	Fase 6 CRISP-DM: despliegue (dashboard)	E4
8	Fase 6 CRISP-DM: informe final, presentación y propuesta de piloto	E5

4.2 Cronograma tentativo (Gantt)

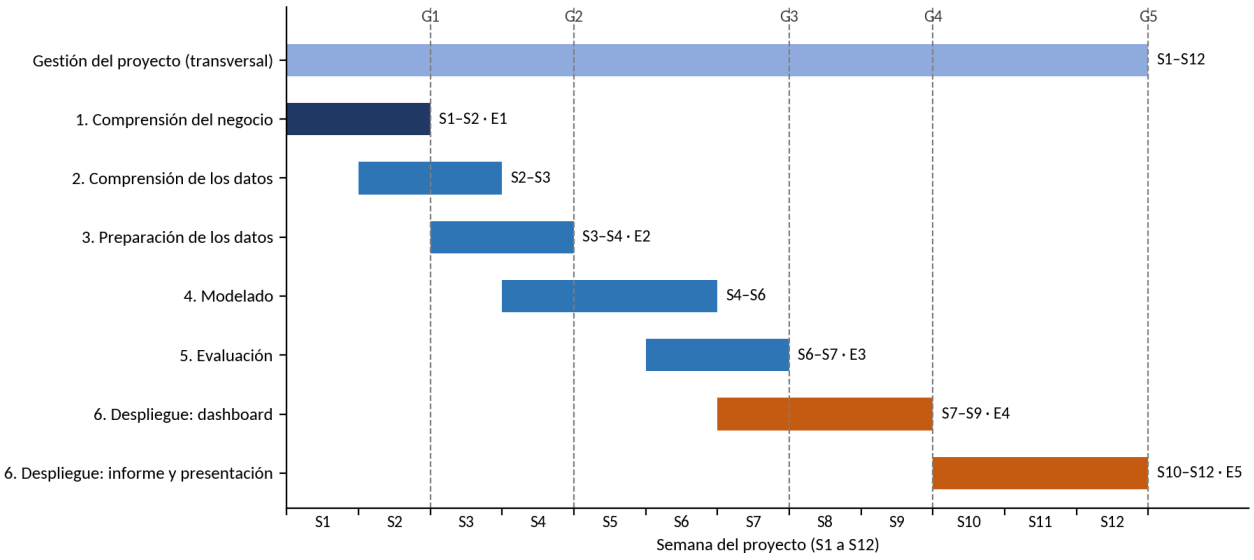


Figura 1. Cronograma de 12 semanas por fases CRISP-DM, con compuertas G1 a G5.

4.3 Equipo del proyecto y presupuesto en USD

Cada rol se asume por el integrante del equipo. La carga de horas proviene de las actividades de la Tabla 8 (200 h). La fase 2 (25 h) se reparte entre el analista de datos (15 h) y el especialista en seguridad (10 h); las 25 h restantes del analista corresponden al dashboard de la fase 6. El pago al proyecto es la hora del rol multiplicada por una tarifa de referencia. Se suma una contingencia de 10% sobre el costo de personal. Las herramientas y el conjunto de datos público no tienen costo.

Rol	Responsabilidades	Horas	Tarifa (USD/h)	Pago (USD)
Jefe de proyecto	Planificación, control de riesgos, comunicación con la aseguradora, negocio	45	12	540
Ingeniero de datos	Integración de la fuente, carga, limpieza y versionado de la base	25	10	250
Especialista en seguridad y cumplimiento	Anonimización, control de acceso y cumplimiento de la Ley N° 19.628	10	12	120
Analista de datos	Análisis exploratorio (15 h) y dashboard (25 h)	40	9	360
Científico de datos	Modelado, validación estadística y reproducibilidad	55	14	770
Analista de negocio	Traducción de resultados, informe y presentación	25	10	250
Subtotal del equipo		200		2.290
Contingencia (10%)				229
Total del análisis				2.519

El programa preventivo propuesto (cesación tabáquica para 250 participantes, coordinación clínica y evaluación del piloto) tiene un presupuesto total de US$ 97.100 con contingencia, equivalente a US$ 388,4 por participante. Es independiente del presupuesto del análisis: el primero financia el análisis y el segundo, la implementación. Las partidas del programa son supuestos de referencia para el ejercicio: la coordinación clínica se estima a US$ 1.500 mensuales durante seis meses, y cada participante a US$ 317.

Partida del programa	Cálculo	USD
Coordinación clínica	6 meses × 1.500	9.000
Participantes del programa	250 × 317	79.250

Partida del programa	Cálculo	USD
Subtotal base		88.250
Contingencia	Ajuste para cuadrar el total de 97.100 (10,03% sobre la base; 10% exacto sería 8.825)	8.850
Total del programa	97.100 ÷ 250 participantes = 388,4 por participante	97.100

4.4 KPIs con riesgo financiero y relación con los objetivos

KPI	Objetivo que mide	Riesgo financiero que controla	Línea base	Meta	Frec.
Desviación del presupuesto del proyecto	Planificación	Sobrecosto del proyecto	0%	±10%	Quincenal
Horas reales vs. planificadas por rol	Planificación	Sobrecosto de personal	200 h	≤ 5% de desviación	Semanal
Error medio del modelo (validación cruzada)	Presupuesto	Error en la estimación del gasto por afiliado	US$ 4.824	No mayor al actual al actualizar datos	Anual
Participación del 10% de mayor costo en el gasto	Presupuesto	Concentración del riesgo financiero	31,8%	Alerta si sube más de 5 puntos	Anual
Reducción del costo anual de fumadores por participante (piloto propuesto)	Prevención	Exposición financiera del grupo de mayor costo	US$ 32.050	≥ 4,9%	Semestral
Costo del programa por participante	Prevención	Costo sin retorno si el programa no reduce costos	US$ 388	≤ US$ 390	Mensual
Hitos cumplidos a tiempo (G1 a G5)	Planificación	Costo de retrasos	—	100%	Quincenal

La meta de reducción de 4,9% se calcula como punto de equilibrio: US$ 390 ÷ (US$ 32.050 × 0,25) ≈ 4,9%. Con la meta anterior de US$ 300 el punto de equilibrio era 3,7%. Ambas cifras dependen del supuesto de cesación de 25%, que se mide en el piloto.

4.5 Matriz de riesgos (nivel de planificación)

ID	Riesgo	Prob.	Impacto	Nivel	Mitigación
R1	La base no incluye diagnósticos ni historial clínico	Alta	Alto	Crítico	Declarar la limitación; proponer incorporar fuentes clínicas.
R2	La muestra no es representativa de la cartera	Media	Alto	Alto	Pedir el método de selección; comparar perfiles en S4.
R3	Incumplimiento de la Ley N° 19.628 con datos de salud	Media	Alto	Alto	Anonimizar identificadores; limitar el acceso a la base.
R4	Interpretación causal de asociaciones	Media	Alto	Alto	Lenguaje asociativo; piloto con grupo de control.
R5	Sobrecosto del equipo por horas adicionales	Media	Medio	Medio	Contingencia de 10%; control semanal de horas (KPI 2).
R6	El programa no reduce costos y se convierte en gasto	Media	Alto	Alto	Compuerta G5 con meta de 4,9%; no ampliar sin evidencia.
R7	Retraso por disponibilidad del integrante	Media	Medio	Medio	Hitos con holgura de una semana.

Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Choi, M. (s.f.). *Insurance* [Conjunto de datos]. Kaggle.

Ley N° 19.628. (1999). *Sobre protección de la vida privada*. Biblioteca del Congreso Nacional de Chile.

Microsoft. (s.f.). *What is the Team Data Science Process?* Microsoft Learn.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

Seabold, S., y Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96.